

# Computació Numèrica

## Part 2.1 - Resolució de sistemes lineals

M. Àngela Grau Gotés

Departament de Matemàtica Aplicada II  
Universitat Politècnica de Catalunya · BarcelonaTech.

6 de març de 2023

“Donat el caràcter i la finalitat exclusivament docent i eminentment il·lustrativa de les explicacions a classe d'aquesta presentació, l'autor s'acull a l'article 32 de la Llei de propietat intel·lectual vigent respecte de l'ús parcial d'obres alienes com ara imatges, gràfics o altre material contingudes en les diferents diapositives”



© 2023 by M. Àngela Grau Gotés.

Licència Creative Commons Atribución-NoComercial-SinDerivadas 4.0 Internacional.

## 1 Sistemes d'Equacions Lineals

- Mètodes directes
  - Mètode de Gauss
  - Mètode de Gauss-Jordan
  - Mètode Compactes
  - Nombre de condició
- Mètodes iteratius
  - Convergència
  - Mètode de Jacobi
  - Mètode de Gauss-Seidel
  - Mètodes de sobrerelaxació
- Sistemes lineals sobredeterminats
  - Equacions normals

## 2 Guia estudi

- Referències

# Àlgebra Lineal Numèrica

L'objectiu principal del tema és l'estudi de mètodes computacionals bàsics per a l'àlgebra lineal.

- Resolució de sistemes lineals no homogenis.
  - ▶ Mètodes directes: eliminació gaussiana, mètode de Gauss-Jordan, descomposició LU, factorització QR.
  - ▶ Mètodes iteratius: Jacobi, Gauss-Seidel i sobrerelaxació
  - ▶ Mínims quadrats.
- Càlcul de vectors i valors propis.
  - ▶ Mètodes de la potència.
  - ▶ Mètode QR.
  - ▶ Valors singulars.



Es parla de sistemes lineals

## 1 Segons tamany

- ▶ Petits ( $n \leq 300$ ),
- ▶ Grans ( $n > 300$ ).

## 2 Segons estructura

- ▶ pocs elements no nuls, matriu plena.
- ▶ bastants elements nuls, triangular superior o inferior.
- ▶ molts elements nuls, matriu tridiagonal, matriu diagonal i matriu sparse.

# Notació matricial

Per a resoldre el sistema, es crea la matriu augmentada:

$$(A|b) = \left( \begin{array}{cccc|c} a_{11} & a_{12} & \dots & a_{1n} & b_1 \\ a_{21} & a_{22} & \dots & a_{2n} & b_2 \\ \vdots & \vdots & & \vdots & \vdots \\ a_{m1} & a_{m2} & \dots & a_{mn} & b_m \end{array} \right)$$

Hi ha sistemes sobredeterminats, amb més equacions que incògnites ( $m > n$ ), hi ha sistemes no determinats, de menys equacions que incògnites ( $n > m$ ) i sistemes amb el mateix nombre d'equacions que incògnites ( $m = n$ ).

# Existència de solucions

Per a un sistema  $Ax = b$  segons el teorema de Rouché-Frobenius, tenim

- $\text{rang}(A) = \text{rang}(A|b) = n$  el sistema és compatible determinat, la solució és única.
- $\text{rang}(A) = \text{rang}(A|b) = r < n$  el sistema és compatible indeterminat, amb  $n - r$  graus de llibertat.
- $\text{rang}(A) \neq \text{rang}(A|b)$  el sistema és incompatible.

Només estudiarem el cas  $n = m$  i  $\det(A) = |A| \neq 0$ , cas de solució és única que es pot calcular fent ús de la Regla de Cramer.



# Mètode de Cramer

Sistema compatible determinat

La solució de  $Ax = b$ , per la regla de Cramer és:

$$x_i = \frac{|A_i|}{|A|}, \quad 1 \leq i \leq n$$

on  $|A|$  és del determinant de la matriu  $a$ , i  $|A_i|$  és el determinant de la matriu  $A_i$  obtinguda substituint la columna  $i$  de la matriu  $A$  pel vector  $b$ .

## Exercici

$$\begin{aligned} 2x_1 + 4x_2 + x_3 &= 1, \\ 8x_1 - x_2 + 3x_3 &= 0, \\ 2x_1 + 5x_2 &= 0. \end{aligned}$$

# Mètode de Cramer - Eficiència

Si la matriu és d'ordre  $n$ ,

- calen  $n + 1$  determinants d'ordre  $n$  per a calcular  $x$ .
- cada determinant d'ordre  $n$  requereix  $n!n - 1$  operacions.
- el nombre d'operacions és, pel cap baix,  $n!(n + 1) - 1$ .

$n$	$10^9$ (Giga)	$10^{10}$	Flops $10^{11}$	$10^{12}$ (Tera)	$10^{15}$ (Peta)
10	$10^{-1}$ sec	$10^{-2}$ sec	$10^{-3}$ sec	$10^{-4}$ sec	negligible
15	17 hours	1.74 hours	10.46 min	1 min	$0.6 \cdot 10^{-1}$ sec
20	4860 years	486 years	48.6 years	4.86 years	1.7 day
25	o.r.	o.r.	o.r.	o.r.	38365 years

Table 5.1. Time required to solve a linear system of dimension  $n$  by the Cramer rule. “o.r.” stands for “out of reach”

És un mètode inapropiat per a l'ordinador.

# Sistemes d'equacions lineals

## Mètodes directes

Documentació de MATLAB® - Sistemes d'equacions lineals

# Mètodes directes

Són mètodes que ens donen la solució exacte en un nombre finit d'operacions, si no fos pels errors d'arrodoniment acumulats i les possibles imprecisions en el coneixement inicial de la matriu de coeficients  $A$  i el terme independent  $b$ .

Es consideren adients per a sistemes lineals no massa grans (100 – 500 equacions) i amb pocs elements nuls.

S'estudien els mètodes,

- Mètode de Gauss.
- Mètodes de factorització  $LU$ , Txoleski i  $QR$ .
- I derivats: Gauss-Jordan, . . . .

# Millor algoritme

En tots els algoritmes caldrà considerar

- el temps emprat per obtenir la solució (mesurat en nombre d'operacions).
- els errors d'arrodoniment del mètode de càlcul.

De res serveix un mètode que obtingui la solució en un temps clarament excésiu.

Primer presentem algorismes molt econòmics computacionalment, i finalment discutirem com afecten els errors d'arrodoniment a la solució obtinguda.

# Sistema diagonal

$D = (d_{ij})$  tal que  $d_{ij} = 0$  si  $i \neq j$  i  $1 \leq i, j \leq n$

$$(D|b) = \left( \begin{array}{cccc|c} d_{11} & 0 & \dots & 0 & b_1 \\ 0 & d_{22} & \dots & 0 & b_2 \\ \vdots & \vdots & & \vdots & \vdots \\ 0 & 0 & \dots & d_{nn} & b_n \end{array} \right)$$

La solució és  $x_i = \frac{b_i}{d_{ii}}$ ,  $1 \leq i \leq n$ .

**Operacions:** calen  $n$  divisions per calcular  $x$ .

# Sistema triangular superior

$U = (u_{ij})$  tal que  $u_{ij} = 0$  si  $1 \leq j < i \leq n$

$$(U|b) = \left( \begin{array}{ccccc|c} u_{11} & u_{12} & u_{13} & \dots & u_{1n} & b_1 \\ 0 & u_{22} & u_{23} & \dots & u_{2n} & b_2 \\ 0 & 0 & u_{33} & \dots & u_{3n} & b_3 \\ \vdots & \vdots & \ddots & \ddots & \vdots & \\ 0 & 0 & \dots & 0 & u_{nn} & b_n \end{array} \right)$$

La solució s'obté per substitució enrera, les fórmules són

$$x_n = \frac{b_n}{u_{nn}}, \quad x_i = \frac{1}{u_{ii}} \left( b_i - \sum_{k=i+1}^n u_{ik} x_k \right), \quad 1 \leq i < n.$$

# Sistema triangular superior

## Exercici

$$\begin{aligned}3x_1 + 2x_2 - 2x_3 + 4x_4 &= -5, \\3x_2 - 5x_3 - 3x_4 &= 0, \\4x_3 + x_4 &= -3, \\2x_4 &= 6.\end{aligned}$$

La solució s'obté per substitució enrera, el resultat és

$$x_4 = 3, \quad x_3 = -3/2, \quad x_2 = 1/2, \quad x_1 = -7,$$



# Sistema triangular inferior

$L = (l_{ij})$  tal que  $l_{ij} = 0$  si  $1 \leq i < j \leq n$

$$(L|b) = \left( \begin{array}{ccccc|c} l_{11} & 0 & 0 & \dots & 0 & b_1 \\ l_{21} & l_{22} & 0 & \dots & 0 & b_2 \\ l_{31} & l_{32} & l_{33} & \ddots & \vdots & b_3 \\ \vdots & \vdots & \vdots & \ddots & 0 & \\ l_{n1} & l_{n2} & l_{n3} & \dots & l_{nn} & b_n \end{array} \right)$$

La solució s'obté per substitució endavant,

$$x_1 = \frac{b_1}{l_{11}}, \quad x_i = \frac{1}{l_{ii}} \left( b_i - \sum_{k=1}^{i-1} l_{ik} x_k \right), \quad 1 < i \leq n.$$

# Nombre d'operacions

**Exercici.** Calculeu el nombre total de

- divisions que calen per resoldre un sistema diagonal.
- divisions que calen per resoldre un sistema triangular.
- multiplicacions que calen per resoldre un sistema triangular.
- sumes que calen per resoldre un sistema triangular.

Ajuda:  $\sum_{i=1}^m i = \frac{(m+1)m}{2}$        $\sum_{i=1}^m i^2 = \frac{m(m+1)(2m+1)}{6}$ .

# Nombre d'operacions

	$+/-$	$*$	$/$	total
Diag	0	0	$n$	$n$
Upper	$\frac{n^2 - n}{2}$	$\frac{n^2 - n}{2}$	$n$	$n^2$
Lower	$\frac{n^2 - n}{2}$	$\frac{n^2 - n}{2}$	$n$	$n^2$

# Mètode d'eliminació de Gauss

Consta de dues fases. La primera fase consisteix en modificar el nostre sistema d'equacions per arribar a un sistema triangular superior. En la segona fase es resol el sistema triangular superior obtingut en la primera fase.

Quin tipus de modificacions són vàlides en la fase 1?

- Multiplicar una fila per un nombre no nul.
- Substituir una fila per una combinació lineal de les altres.
- Permutar files del sistema.
- Permutar columnes del sistema.

Les files són equacions i les columnes són incògnites.

# Exemple. Mètode d'eliminació de Gauss

$$\begin{aligned}2x_1 + 4x_2 + x_3 &= 1, \\8x_1 - x_2 + 3x_3 &= 0, \\2x_1 + 5x_2 &= 0.\end{aligned}$$

$$G^{(0)} = \begin{pmatrix} 2 & 4 & 1 & 1 \\ 8 & -1 & 3 & 0 \\ 2 & 5 & 1 & 0 \end{pmatrix} \rightsquigarrow G^{(1)} = \begin{pmatrix} 2 & 4 & 1 & 1 \\ 0 & -17 & -1 & -4 \\ 0 & 1 & -1 & -1 \end{pmatrix}$$

$$G^{(2)} = \begin{pmatrix} 2 & 4 & 1 & 1 \\ 0 & -17 & -1 & -4 \\ 0 & 0 & -\frac{18}{17} & -\frac{21}{17} \end{pmatrix} \rightarrow x = \begin{pmatrix} -5/12 \\ 1/6 \\ 7/6 \end{pmatrix}$$

# Mètode d'eliminació de Gauss

L'algoritme de Gauss, s'aplica sobre la matriu ampliada; i converteix la matriu en una matriu triangular superior. La matriu del sistema  $A$  és reduïda a triangular superior en  $n - 1$  passos si  $A$  té  $n$  files.

$$\left( \begin{array}{ccccc|c} a_{11} & a_{12} & a_{13} & \dots & a_{1n} & b_1 \\ a_{21} & a_{22} & a_{23} & \dots & a_{2n} & b_2 \\ a_{31} & a_{32} & a_{33} & \dots & a_{3n} & b_3 \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ a_{n1} & a_{n2} & a_{n3} & \dots & a_{nn} & b_n \end{array} \right) \rightsquigarrow \left( \begin{array}{ccccc|c} u_{11} & u_{12} & u_{13} & \dots & u_{1n} & \tilde{b}_1 \\ 0 & u_{22} & u_{23} & \dots & u_{2n} & \tilde{b}_2 \\ 0 & 0 & u_{33} & \dots & u_{3n} & \tilde{b}_3 \\ \vdots & \vdots & \ddots & \ddots & \vdots & \vdots \\ 0 & 0 & \dots & 0 & u_{nn} & \tilde{b}_n \end{array} \right)$$

# Mètode de Gauss. Pas 1

Escrivim el sistema lineal de partida com per  $G^{(0)}$  la matriu  $(A|b)$ , el primer pas és

- verifico si  $a_{11} \neq 0$ , (pivot).
- s'escull la fila 1, (fila pivot).
- per cada fila per sota de la fila pivot calculo  $m_{i1} = \frac{a_{i1}}{a_{11}}$ , (multiplicador).
- per cada fila per sota de la fila pivot resto  $m_{i1}$  vegades la fila pivot de la fila  $i$ .

El resultat és una matriu,  $G^{(1)}$ , amb la primera columna tot zero, llevat de  $a_{11}$ .

El nombre de divisions és  $n - 1$ , i per cada fila són  $n$  productes i sumes; en total  $n(n - 1)$ .

# Mètode de Gauss. Pas 2

El segon pas és,

- fila pivot la fila 2 de la matriu  $G^{(1)}$ .
- verifico si el pivot no és nul,  $a_{22}^{(1)} \neq 0$ .
- per cada fila per sota de la fila pivot calculo

$$m_{i2} = a_{i2}^{(1)} / a_{22}^{(1)}.$$

- per cada fila per sota de la fila pivot resto  $m_{i1}$  vegades la fila pivot de la fila  $i$ .

El resultat és una matriu,  $G^{(2)}$ , amb la segona columna tot zero, llevat de  $a_{22}^{(2)}$  i  $a_{12}^{(2)}$ .

El nombre de divisions és  $n - 2$ , i per cada fila són  $n - 1$  productes i sumes; en total  $(n - 1)(n - 2)$ .



# Mètode de Gauss. Pas $k$

En general, en el pas  $k < n$ , reduïm la columna  $r$  de la matriu  $G^{(k-1)}$ , modificant des de la fila  $k$  fins a la  $n$  amb la fórmula

$$m_{ik} = \frac{a_{ik}^{(k-1)}}{a_{kk}^{(k-1)}}, \quad i = k + 1 \dots n,$$

$$\text{NovaFila}(i) = \text{Fila}(i) - m_{ik} \cdot \text{Fila}(k), \quad i = k + 1 \dots n.$$

El nombre de divisions és  $n - k$ , i per cada fila són  $n - k$  productes i sumes; en total  $(n - k)(n - k + 1)$ .

# Operacions triangular superior

El nombre total de divisions és

$$\sum_{k=1}^{n-1} (n - k) = \frac{1}{2}n(n - 1) = \frac{n^2}{2} + o(n).$$

El nombre total de multiplicacions/sumes és

$$\begin{aligned}\sum_{k=1}^{n-1} (n - k + 1)(n - k) &= \sum_{k=1}^{n-1} (n^2 + n - k(2n + 1) + k^2) = \\ &= (n^2 + n)(n - 1) - (2n + 1)\frac{n(n - 1)}{2} + \frac{n(n - 1)(2n - 1)}{6} = \\ &= \frac{n(n - 1)(n + 2)}{3} = \frac{n^3}{3} + o(n^2).\end{aligned}$$

# Nombre operaciones

Algunos costes con el método de Gauss		
$n$	Coste del Método de Gauss	Tiempo ( $10^6$ oper/s)
5	90	90 microsegundos
10	705	0,7 milisegundos
20	5510	5,5 milisegundos
100	671550	0,67 segundos
1000	667 millones	11 minutos

$n$	Flops $10^9$ (Giga)	$10^{12}$ (Tera)	$10^{15}$ (Peta)
$10^2$	$7 \cdot 10^{-4}$ sec	negligible	negligible
$10^4$	11 min	0.7 sec	$7 \cdot 10^{-4}$ sec
$10^6$	21 years	7.7 months	11 min
$10^8$	o.r.	o.r.	21 years

**Table 5.3.** Time required to solve a full linear system of dimension  $n$  by MEG. “o.r.” stands for “out of reach”

# Estratègies de pivotar

- Què passa si el pivot del pas  $k$  és zero?

**Pivot trivial** Es busca la primera fila per sota de la fila  $k$  que tingui valor no nul, i s'intercanvien les dues files.

## Exemples

$$\left( \begin{array}{cc|c} 0 & 1 & 1 \\ 1 & 0 & 0 \end{array} \right)$$

$$\begin{aligned} x_1 + 3x_2 + x_3 &= -3, \\ 3x_1 + 9x_2 + 4x_3 &= -7, \\ 2x_1 - x_2 + x_3 &= 6. \end{aligned}$$

# Estratègies de pivotar

- Què passa si el pivot del pas  $k$  és proper a zero?

**Pivot parcial.** S'agafa com a pivot l'element de més gran magnitud de tota la columna  $k$ .

**Pivot parcial escalat.** S'agafa com a pivot l'element de la columna  $k$  o per sota de la diagonal principal que té la grandària relativa més gran respecte dels altres elements de la fila.

**Exemple.**

$$\left( \begin{array}{cc|c} \epsilon & 1 & 1 \\ 1 & 1 & 2 \end{array} \right)$$

$$\begin{aligned} -10^{-5}x_1 + x_2 &= 1, \\ 2x_1 + x_2 &= 0. \end{aligned}$$

# Mètode de Gauss-Jordan

Per a resoldre el sistema, es transforma la matriu  $A$  en una matriu diagonal:

$$(A|b) \Rightarrow (D|\bar{b})$$

$$\left( \begin{array}{cccc|c} a_{11} & a_{12} & \dots & a_{1n} & b_1 \\ a_{21} & a_{22} & \dots & a_{2n} & b_2 \\ a_{31} & a_{32} & \dots & a_{3n} & b_2 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ a_{n1} & a_{n2} & \dots & a_{nn} & b_n \end{array} \right) \Rightarrow \left( \begin{array}{ccccc|c} a_{11} & 0 & 0 & \dots & 0 & b_1 \\ 0 & a_{22} & 0 & \dots & 0 & b_2 \\ 0 & 0 & a_{33} & \dots & 0 & b_3 \\ \vdots & \vdots & \ddots & \ddots & \vdots & \\ 0 & 0 & \dots & 0 & a_{nn} & b_n \end{array} \right)$$

# Mètode de Gauss-Jordan. Pas $k$

En general, en el pas  $k < n$ , reduïm la columna  $k$  de la matriu  $G^{(k-1)}$ , modificant totes les files, llevat de la fila  $k$ , amb la fórmula

$$m_{ik} = \frac{a_{ik}^{(k-1)}}{a_{kk}^{(k-1)}}, \quad i \neq k,$$

$$\text{NovaFila}(i) = \text{Fila}(i) - m_{ik} \cdot \text{Fila}(k), \quad i \neq k.$$

Comentari: el sistema diagonal és més fàcil de resoldre, però la reducció a sistema diagonal és més costosa.

El mètode de Gauss és numèricament estable i no cal fer intercanvis de files i columnes si

- si la matriu  $A$  és diagonal dominant.
- si la matriu  $A$  és simètrica i definida positiva.

|

Simètrica si  $A^t = A$ . Definida positiva si  $x^t A x > 0$ ,  $\forall x \neq 0$ .

Diagonal dominant si  $|a_{ii}| \geq \sum_{\substack{i \neq j \\ 1 \leq j \leq n}} |a_{ij}|$ ,  $1 \leq i \leq n$ .



# Aplicacions.

El mètode de Gauss s'usa:

- per a resoldre sistemes,
- per a calcular el determinant d'una matriu,
- per a calcular el rang d'una matriu.

El mètode de Gauss-Jordan s'usa per a trobar matrius inverses.

$$A = \begin{pmatrix} 6 & 2 & 1 & -1 \\ 2 & 4 & 1 & 0 \\ 1 & 1 & 4 & -1 \\ -1 & 0 & -1 & 3 \end{pmatrix}$$

# Sistemes d'equacions lineals

## Mètodes compactes

Documentació de MATLAB® - Factoritzacions

# Mètodes Compactes

El tret principal d'aquests mètodes es treballar sols amb la matriu  $A$  i presentar-la com  $A = BC$  on  $B$  i  $C$  són matrius més fàcils d'invertir (nombre operacions).

Descomposicions més conegudes són<sup>1</sup>

- $A = LU$ ,  $L$  triangular inferior i  $U$  triangular superior.
- $A = R^t R$ ,  $R$  triangular superior i  $A$  sim. def. pos.
- $A = QR$ ,  $Q$  ortogonal i  $R$  triangular superior.
- $A = U\Sigma V^t$ ,  $U$  i  $V$  ortogonals i  $\Sigma$  diagonal.

---

<sup>1</sup> $LU$  i  $R^t R$  matrius  $n \times n$ ,  $QR$  i  $U\Sigma V'$  matrius  $n \times m$

# Factorització $LU$

$$A = \begin{pmatrix} l_{11} & 0 & 0 & \dots & 0 \\ l_{21} & l_{22} & 0 & \dots & 0 \\ l_{31} & l_{32} & l_{33} & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ l_{n1} & l_{n2} & l_{n3} & \dots & l_{nn} \end{pmatrix} \begin{pmatrix} u_{11} & u_{12} & u_{13} & \dots & u_{1n} \\ 0 & u_{22} & u_{23} & \dots & u_{2n} \\ 0 & 0 & u_{33} & \dots & u_{3n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \dots & u_{nn} \end{pmatrix}$$

- És un sistema de  $n^2$  equacions i  $n^2 + n$  incògnites.
- Comentari 1: Mètode de Doolittle,  $l_{ii} = 1$ .
- Comentari 2: Mètode de Crout,  $u_{ij} = 1$ .
- Comentari 3: sense pivotar,  $L$  és la matriu dels multiplicadors i  $U$  és la matriu resultant del mètode de Gauss a la matriu  $A$ .

## Algoritmo de la Factorización $LU$

Para  $k = 1, \dots, n$ ,

$$\begin{aligned} \ell_{kk} u_{kk} &= a_{kk} - \sum_{r=1}^{k-1} \ell_{kr} u_{rk}; \\ \ell_{ik} &= \frac{a_{ik} - \sum_{r=1}^{k-1} \ell_{ir} u_{rk}}{u_{kk}}, \quad i = k+1, \dots, n; \\ u_{kj} &= \frac{a_{kj} - \sum_{r=1}^{k-1} \ell_{kr} u_{rj}}{\ell_{kk}}, \quad j = k+1, \dots, n. \end{aligned}$$

El cost de la factorització és  $\frac{4n^3 + 2n}{6}$ .

# Exercici

Calculeu la factorització  $LU$  de la matriu

$$A = \begin{pmatrix} 6 & 2 & 1 & -1 \\ 2 & 4 & 1 & 0 \\ 1 & 1 & 4 & -1 \\ -1 & 0 & -1 & 3 \end{pmatrix}$$

## Matlab

```
A=[6,2,1,-1; 2,4,1,0;1,1,4,-1;-1,0,-1,3]
```

```
[L,U]=A o [L,U,P]=lu(A)
```

# Factorització $LU$

Notem per  $A_i$  les submatrius de la matriu  $A$  formades per les  $i$  primeres files i les  $i$  columnes de la matriu  $A$ .

## Existència

Una matriu  $A$ , regular, admet factorització  $LU$  si i només si totes les matrius  $A_i$ ,  $i = 1, \dots, n$ , són regulars.

- Si  $A$  és diagonal dominant, admet factorització  $LU$ .
- Si  $A$  és simètrica i definida positiva, admet factorització  $LU$ .

La resolució del sistema lineal  $Ax = b$  fent ús de  $PA = LU$ ,  $L$  triangular inferior i  $U$  triangular superior, és en dos passos:

- Pas 1, es calcula  $Ly = Pb$  (endavant).
- Pas 2, es calcula  $Ux = y$  (enrera).

# Factorització Txoleski

Trobeu la factorització  $A = R^t R$  i resoleu després el sistema lineal  $Ax = b$ ,

$$A = \begin{pmatrix} 16 & 4 & 0 & -4 \\ 4 & 5 & 2 & -1 \\ 0 & 2 & 2 & -2 \\ -4 & -1 & -2 & 6 \end{pmatrix} \quad b = \begin{pmatrix} 8 \\ -2 \\ -4 \\ 3 \end{pmatrix} \quad \Rightarrow \quad R = \begin{pmatrix} 4 & 1 & 0 & -1 \\ 0 & 2 & 1 & 0 \\ 0 & 0 & 1 & -2 \\ 0 & 0 & 0 & 1 \end{pmatrix}$$

## Existència

Tota matriu  $A$  simètrica i definida positiva es pot factoritzar com  $A = R^t R$  per  $R$  triangular superior o  $A = SS^t$  per  $S$  triangular inferior (factorització de Txoleski).

Serveix com a test per dir si una matriu és definida positiva.



## Método de Cholesky

Para  $k = 1, \dots, n$ ,

$$\ell_{kk} = \sqrt{a_{kk} - \sum_{r=1}^{k-1} \ell_{k,r}^2};$$
$$\ell_{i,k} = \frac{a_{i,k} - \sum_{r=1}^{k-1} \ell_{i,r} \ell_{k,r}}{\ell_{kk}}, \quad i = k+1, \dots, n.$$

El cost de la factorització és  $\mathcal{O}(n^3)$ .

# Factorització $QR$

La factorització  $QR$  expressa la matriu  $A$  com el producte de dues matrius, una ortogonal ( $Q^t Q = I$ ) i l'altre triangular superior ( $R$ ). Així, el sistema lineal  $Ax = b$  es reduïx a resoldre  $Rx = Q^t b$ .

Aquesta factorització és més costosa que la **LU** però les matrius  $A$  i  $R = Q^t A$  tenen el mateix nombre de condició.

La factorització **QR** no és única.

- Mètode de les rotacions de Givens.
- Mètode de Gram-Schmidt d'ortogonalització.
- Mètode de les reflexions de Householder (1958).

## Transformacions de Householder

Per  $v \in \mathbb{R}^n$  definim la transformació associada a  $v$  per

$$H = \begin{cases} I, & v = 0, \\ I - \frac{2}{v^t v} vv^t, & v \neq 0. \end{cases}$$

## Propietats

- ❶  $H$  és simètrica, ortogonal i  $H^2 = I$ .
- ❷ Si  $x \perp v, \Rightarrow Hx = x$ .
- ❸ Si  $x \parallel v, \Rightarrow Hx = -x$   $Hv = -v$ .
- ❹ Si  $\|x\| = \|v\|, v = x - y, \Rightarrow Hx = y$ .

# Factorització $QR$

Per  $A$  és una matriu  $m \times n$ , les matrius ortogonals  $Q_k$  modifiquen les files  $k, \dots, m$  de la manera següent:

$$\begin{array}{c} \begin{bmatrix} x & x & x \\ x & x & x \\ x & x & x \\ x & x & x \\ x & x & x \end{bmatrix} \\ A \end{array} \xrightarrow{Q_1} \begin{array}{c} \begin{bmatrix} * & * & * \\ 0 & * & * \\ 0 & * & * \\ 0 & * & * \\ 0 & * & * \end{bmatrix} \\ Q_1 A \end{array} \xrightarrow{Q_2} \begin{array}{c} \begin{bmatrix} x & x & x \\ 0 & * & * \\ 0 & 0 & * \\ 0 & 0 & * \\ 0 & 0 & * \end{bmatrix} \\ Q_2 Q_1 A \end{array} \xrightarrow{Q_3} \begin{array}{c} \begin{bmatrix} x & x & x \\ 0 & x & x \\ 0 & 0 & * \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix} \\ Q_3 Q_2 Q_1 A \end{array}$$

De  $Q_n Q_{n-1} \dots Q_1 A = R$ , construïm

$$A = \underbrace{Q_1^t \dots Q_{n-1}^t Q_n^t}_Q R = QR$$

Són una successió de simetries per transformar les columnes de la matriu  $A$  a una forma triangular superior

# Factorització $QR$

$$[\mathbf{Ax} = \mathbf{b}] \equiv \begin{pmatrix} 1 & -1 & -1 \\ 2 & 0 & 1 \\ -2 & 7 & 1 \end{pmatrix} \begin{pmatrix} x \\ y \\ z \end{pmatrix} = \begin{pmatrix} 0 \\ 4 \\ -7 \end{pmatrix}$$

$$\left\| \begin{pmatrix} 1 \\ 2 \\ -2 \end{pmatrix} \right\| = 3, \Rightarrow y^{(1)} = \begin{pmatrix} 3 \\ 0 \\ 0 \end{pmatrix},$$

$$v^{(1)} = x^{(1)} - y^{(1)} = \begin{pmatrix} -2 \\ 2 \\ -2 \end{pmatrix}.$$

# Factorització QR

$$H_1 = I - \frac{2}{v_1^* v_1} v_1 v_1^* = I - \frac{2}{12} \begin{pmatrix} -2 \\ 2 \\ -2 \end{pmatrix} \begin{pmatrix} -2 & 2 & -2 \end{pmatrix} = \begin{pmatrix} 1/3 & 2/3 & -2/3 \\ 2/3 & 1/3 & 2/3 \\ -2/3 & 2/3 & 1/3 \end{pmatrix}$$

$$H_1 A = \begin{pmatrix} 1/3 & 2/3 & -2/3 \\ 2/3 & 1/3 & 2/3 \\ -2/3 & 2/3 & 1/3 \end{pmatrix} \begin{pmatrix} 1 & -1 & -1 \\ 2 & 0 & 1 \\ -2 & 7 & 1 \end{pmatrix} = \begin{pmatrix} 3 & -5 & -1/3 \\ 0 & 4 & 1/3 \\ 0 & 3 & 5/3 \end{pmatrix}$$

$$x_2 = \begin{pmatrix} -5 \\ 4 \\ 3 \end{pmatrix} \quad y_2 = \begin{pmatrix} -5 \\ \sqrt{4^2 + 3^2} \\ 0 \end{pmatrix} = \begin{pmatrix} -5 \\ 5 \\ 0 \end{pmatrix} \Rightarrow v_2 = x_2 - y_2 = \begin{pmatrix} 0 \\ -1 \\ 3 \end{pmatrix}$$

$$H_2 = I - \frac{2}{v_2^* v_2} v_2 v_2^* = I - \frac{2}{10} \begin{pmatrix} 0 \\ -1 \\ 3 \end{pmatrix} \begin{pmatrix} 0 & -1 & 3 \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 4/5 & 3/5 \\ 0 & 3/5 & -4/5 \end{pmatrix}$$

# Factorització $QR$

Per  $A$  i  $R$  matrius  $m \times n$  i  $Q$  matriu  $m \times m$ ,  $A = QR$

En Matlab la factorització  $QR$  s'obté per  $[Q, R, P] = \text{qr}(A)$ .

En aquest cas, la resolució del sistema lineal  $Ax = b$  amb  $AP = QR$ ,  $R$  triangular inferior i  $Q$  ortogonal, és en dos passos:

- Pas 1, es calcula  $B = Q'Pb$ .
- Pas 2, es resol el sistema triangular  $Rx = B$ .

Les matrius  $A$  i  $R = Q'A$  tenen el mateix nombre de condició.

# Sistemes d'equacions lineals

## Vector residu i errors



# Condicionament

## Exemple

$$(A|b) = \left( \begin{array}{cccc|c} 10 & 7 & 8 & 7 & 32 \\ 7 & 5 & 6 & 5 & 23 \\ 8 & 6 & 10 & 9 & 33 \\ 7 & 5 & 9 & 10 & 31 \end{array} \right) \xrightarrow{\text{sol. exacte}} \begin{pmatrix} 1 \\ 1 \\ 1 \\ 1 \end{pmatrix} \quad (1)$$

$$(A|b) = \left( \begin{array}{cccc|c} 10 & 7 & 8 & 7 & 32.1 \\ 7 & 5 & 6 & 5 & 22.9 \\ 8 & 6 & 10 & 9 & 33.1 \\ 7 & 5 & 9 & 10 & 30.9 \end{array} \right) \xrightarrow{\text{sol. exacte}} \begin{pmatrix} ? \\ ? \\ ? \\ ? \end{pmatrix} \quad (2)$$

Una petita modificació en les dades (terme independent) dóna lloc a una gran modificació en el resultat (solució)

# Condicionament

Un sistema d'equacions lineals  $Ax = b$  es diu *ben condicionat* quan els errors de la matriu de coeficients  $A$  i del vector terme independent  $b$  produeixen en la solució un error del mateix ordre.

Un sistema d'equacions lineals  $Ax = b$  es diu *mal condicionat* quan els errors de la matriu de coeficients  $A$  i del vector terme independent  $b$  produeixen en la solució del sistema un error d'ordre superior en al de les dades.

$$\begin{matrix} \|A - \bar{A}\| < \epsilon \\ \|b - \bar{b}\| < \epsilon \end{matrix} \implies \begin{cases} \|x - \bar{x}\| \simeq \epsilon, & \text{ben condicionat,} \\ \|x - \bar{x}\| \gg \epsilon, & \text{mal condicionat,} \end{cases}$$

# Nombre de condició

Es diu que el sistema  $Ax = B$  està mal condicionat si  $A$  té un nombre de condició gran.

## Nombre de condició

$$\mathcal{K}(A) = \begin{cases} \|A\| \|A^{-1}\|, & \det(A) \neq 0 \\ \infty, & \text{altrament} \end{cases}$$

## Propietats

- $\mathcal{K}(A) \geq 1$ ,  $\mathcal{K}(I) = 1$ .
- Si  $B = zA$ , per  $z \neq 0$  real, llavors  $\mathcal{K}(B) = \mathcal{K}(A)$ .
- $\mathcal{K}(AB) \leq \mathcal{K}(A) \mathcal{K}(B)$ .
- $\mathcal{K}_2(AB) = \sigma_n / \sigma_1$ .
- $\mathcal{K}_2(A) = \mathcal{K}_2(AQ) = \mathcal{K}_2(QA)$  per  $Q$  matriu ortogonal.

# Fites de l'error

Si  $x^* = x + \delta x$ , en el sistema lineal  $Ax = b$  es verifica<sup>2</sup>:

$$\text{Errors en } b \quad \frac{\|\delta x\|}{\|x\|} \leq \mathcal{K}(A) \frac{\|\delta b\|}{\|b\|} \quad (3)$$

$$\text{Errors en } A \quad \frac{\|\delta x\|}{\|x + \delta x\|} \leq \mathcal{K}(A) \frac{\|\delta A\|}{\|A\|} \quad (4)$$

$$\text{Errors en } A \text{ i } b \quad \frac{\|\delta x\|}{\|x\|} \leq \mathcal{K}(A) \left( \frac{\|\delta A\|}{\|A\|} \frac{\|x + \delta x\|}{\|x\|} + \frac{\|\delta b\|}{\|b\|} \right) \quad (5)$$

---

<sup>2</sup>Aquest resultat el podeu trobat en la primera referència bibliogràfica.

# Vector residu i error

Com a criteri de comparació entre la solució exacta  $x$ , i la solució calculada  $x^* = x + \delta x$ , del sistema lineal  $Ax = b$  definim el vector residu  $r(x^*)$  per:

$$r(x^*) = A\delta x = Ax - Ax^* = b - Ax^*.$$

Llavors es verifica<sup>3</sup>:

$$\frac{\|\delta x\|}{\|x\|} \leq \mathcal{K}(A) \frac{\|\delta b\|}{\|b\|} = \mathcal{K}(A) \frac{\|r(x^*)\|}{\|b\|} \quad (6)$$

---

<sup>3</sup>Aquest resultat el podeu trobat en la primera referència bibliogràfica.

# Sistemes d'equacions lineals

## Mètodes iteratius

Documentació de MATLAB® - Iterative Methods for Linear Systems

# Mètodes iteratius

Mètodes iteratius estacionaris, mètodes iteratius no estacionaris

Són mètodes que construeixen una successió de vectors convergent a la solució exacte amb un nombre finit d'operacions en cada iteració, si no fos pels errors d'arrodoniment acumulats i les possibles imprecisions en el coneixement inicial de la matriu  $A$  i el vector  $b$ .

Es consideren adients per a sistemes lineals d'ordre alt.

Treballarem tres mètodes,

- mètode de Jacobi.
- mètode de Gauss-Seidel
- mètodes de Sobrerelaxació

# Mètodes iteratius estacionaris

Transformen el sistema lineal  $Ax = b$  com  $x = Bx + c$ . Els dos sistemes han de ser consistents.

$$\left. \begin{array}{l} Ax = b \\ Ax^* = b \end{array} \right\} \iff \left\{ \begin{array}{l} x^{(k+1)} = Bx^{(k)} + c \\ x^* = Bx^* + c \end{array} \right.$$

## Algorisme

Partim de  $x^{(0)}$  arbitrari, i generem la successió de vectors  $x^{(k)}$  a partir de la recurrència  $x^{(k+1)} = Bx^{(k)} + c$ .

## Cost computacional

Cada iteració són  $n^2$  sumes i  $n^2$  productes; després de  $k$  iteracions són  $2n^2k$ .

## Convergent?

La successió de vectors  $x^{(k)}$  és convergent a  $x^*$ , solució de  $Ax = b$ ?



# Teoremes de convergència

## Teorema I

Si  $A$  és no singular, definim  $r^{(k)} = b - Ax^{(k)}$

$$\lim_{k \rightarrow \infty} x^{(k)} = x^* \iff \lim_{k \rightarrow \infty} r^{(k)} = 0.$$

## Teorema II

El mètode iteratiu  $x^{(k+1)} = Bx^{(k)} + c$  és convergent a la solució  $x^*$  per qualsevol  $x^{(0)} \iff \rho(B) < 1$ .

Vector residu:  $r^{(k)} = b - Ax^{(k)}$ .

# Fites de l'error

- Raó de convergència

- $x^{(k)} - x^* = B \left( x^{(k-1)} - x^* \right) = \dots = B^k \left( x^{(0)} - x^* \right) \Rightarrow$

$$\|x^{(k)} - x^*\| = \|B\|^k \|x^{(0)} - x^*\|$$

- Fites de l'error

- $x^{(k)} - x^* = -B \left( x^{(k)} - x^{(k-1)} \right) + B \left( x^{(k)} - x^* \right) \Rightarrow$

$$\|x^{(k)} - x^*\| = \frac{\beta}{1 - \beta} \|x^{(k)} - x^{(k-1)}\|, \quad \beta = \|B\| < 1.$$

- $B \left( x^{(k)} - x^{(k-1)} \right) = B^k \left( x^{(1)} - x^{(0)} \right) \Rightarrow$

$$\|x^{(k)} - x^*\| = \frac{\beta^k}{1 - \beta} \|x^{(1)} - x^{(0)}\|, \quad \beta = \|B\| < 1.$$

# Mètode general

$$A = \begin{pmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \dots & a_{nn} \end{pmatrix}$$

Per convertir  $Ax = b$  en un sistema de la forma  $x = Bx + c$ , expressem la matriu  $A$  com a suma de tres matrius:  $A = L + D + U$  tals

$$\underbrace{\begin{pmatrix} 0 & 0 & \dots & 0 \\ a_{21} & 0 & \dots & 0 \\ \vdots & \ddots & \ddots & \vdots \\ a_{n1} & \dots & a_{nn-1} & 0 \end{pmatrix}}_L + \underbrace{\begin{pmatrix} a_{11} & 0 & \dots & 0 \\ 0 & a_{22} & 0 & \dots & 0 \\ \vdots & \ddots & \ddots & \vdots \\ 0 & \dots & 0 & a_{nn} \end{pmatrix}}_D + \underbrace{\begin{pmatrix} 0 & a_{12} & \dots & a_{1n} \\ 0 & 0 & \dots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 0 \end{pmatrix}}_U$$

# Exemple

Determineu les matrius d'iteració del mètode de Jacobi i del mètode Gauss-Seidel del sistema  $Ax = b$  donat per

$$A = \begin{pmatrix} 1 & 0 & 1 \\ -1 & 1 & 0 \\ 1 & 2 & -3 \end{pmatrix} \quad b = \begin{pmatrix} 4 \\ 1 \\ -4 \end{pmatrix}$$

que té per solució  $x^* = (1, 2, 3)^\top$ .

# Mètode de Jacobi

## Construcció matrius

El mètode Jacobi es basa en la resolució de cada variable localment respecte a les altres variables.

$$\left. \begin{array}{l} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n = b_1 \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n = b_2 \\ \vdots \\ a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{nn}x_n = b_n \end{array} \right\} \Longleftrightarrow \begin{cases} x_i^{(k+1)} = \frac{1}{a_{ii}} \left( b_i - \sum_{\substack{j=1 \\ j \neq i}}^n a_{ij}x_j^{(k)} \right) \\ i = 1, 2, \dots, n, \quad k \geq 0. \end{cases}$$

## Notació Matricial

$$Ax = b \Longleftrightarrow x^{(k+1)} = B_j x^{(k)} + c_j, \quad \forall k \geq 0.$$

La matriu d'iteració del mètode  $B_j = -D^{-1}(L + U)$  i el vector  $c_j = D^{-1}b$

Si  $A$  és diagonal dominant estricta el mètode és convergent.

# Mètode de Gauss-Seidel

## Construcció matrius

El mètode Gauss-Seidel és com el mètode Jacobi, excepte que utilitza valors actualitzats tan aviat com estiguin disponibles.

$$\left. \begin{array}{l} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n = b_1 \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n = b_2 \\ \vdots \\ a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{nn}x_n = b_n \end{array} \right\} \iff \left\{ \begin{array}{l} x_i^{(k+1)} = \frac{1}{a_{ii}} \left( b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij}x_j^{(k)} \right) \\ i = 1, 2, \dots, n, \quad k \geq 0. \end{array} \right.$$

## Notació Matricial

$$Ax = b \iff x^{(k+1)} = B_{GS} x^{(k)} + c_{GS}, \quad \forall k \geq 0.$$

La matriu d'iteració és  $B_{GS} = -(L + D)^{-1}U$  i el vector és  $c_{GS} = (L + D)^{-1}b$

Si  $A$  és diagonal dominant estricta, el mètode és convergent.

Si  $A$  és simètrica definida positiva, el mètode és convergent.

# Mètodes de sobrerelaxació

## Mètodes de relaxació - variant JACOBI

Són una generalització dels dos mètodes estudiats; sumem i restem  $x_i^k$  en l'expressió del mètode de Jacobi,

$$x_{ji}^{(k+1)} = x_i^{(k)} + \underbrace{\frac{1}{a_{ii}} \left( b_i - \sum_{j=1}^n a_{ij} x_j^{(k)} \right)}_{\text{correcció}}, \quad k \geq 0.$$

El mètode de relaxació consisteix en multiplicar la correcció per un paràmetre  $\omega$ , **paràmetre de relaxació**, de manera que s'acceleri la convergència. En termes matricials seria:

✓  $C = D^{-1}$  Matriu auxiliar.

✓  $B_{sor} = C ((1 - \omega)D - \omega(L + U))$  Matriu d'iteració.

✓  $c_{sor} = \omega C b$  Vector d'iteració.

# Mètodes de sobrerelaxació

## Mètodes de relaxació - variant SEIDEL

El mètode de relaxació consisteix en multiplicar la correcció per un paràmetre  $\omega$ , **paràmetre de relaxació**, de manera que s'acceleri la convergència. Per components seria:

$$x_i^{(k+1)} = x_i^{(k)} + \omega \underbrace{\frac{1}{a_{ii}} \left( b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i}^n a_{ij} x_j^{(k)} \right)}_{\text{correcció}}, \quad k \geq 0.$$

$$x_i^{(k+1)} = \omega x_{Si}^{(k+1)} + (1 - \omega) x_i^{(k)}, \quad k \geq 0.$$

En termes matricials seria:

$$\checkmark \quad C = (D + \omega L)^{-1}$$

Matriu auxiliar.

$$\checkmark \quad B_{sor} = C ((1 - \omega)D - \omega U)$$

Matriu d'iteració.

$$\checkmark \quad c_{sor} = \omega C b$$

Vector d'iteració.



# Mètodes de sobrerelaxació

Variant Seidel

## Convergència

Si la matriu  $A$  té tots els elements diagonals no nuls, llavors

$$|\omega - 1| \leq \rho(B_{sor}).$$

Per convergència només possible  $\omega \in (0, 2)$ .

- ✓ Si  $\omega = 1$  és el mètode de Gauss-Seidel.
- ✓ Si  $0 < \omega < 1$  mètodes de subrelaxació.
- ✓ Si  $1 < \omega < 2$  mètodes de sobrerelaxació.

# Mètodes de sobrerelaxació

## Convergència

**TEOREMA.** *Sigui  $A$  simètrica, definida positiva i tridiagonal en blocs:*

$$A = \begin{pmatrix} D_1 & U_1 & & \\ L_2 & D_2 & U_2 & 0 \\ & 0 & & U_{n-1} \\ & & L_n & D_n \end{pmatrix}$$

on  $D_i$ ,  $i = 1, \dots, n$  són submatrius diagonals,  $U_i$ ,  $L_i$ , submatrius qualssevol que satisfan  $L_{i+1} = U_i^T$ ,  $i = 1, \dots, n-1$ . Llavors  $\rho(B_{GS}) = \rho^2(B_J)$  i el paràmetre de relaxació  $\bar{w}$  òptim és

$$\bar{w} = \frac{2}{1 + (1 - \rho(B_{GS}))^{1/2}}, \quad \rho(B_{GS}) < 1,$$

on  $\rho(B_J)$  és el radi espectral de la iteració de Jacobi corresponent a  $A$ . El valor òptim de  $\rho(B_w)$  és

$$\rho(B_{\bar{w}}) = \bar{w} - 1.$$

# Mètodes de sobrerelaxació

## Variant Seidel

Si la matriu  $A$  verifica les hipotesis del teorema anterior resulta que,

$$\rho(B_{GS}) = (\rho(B_J))^2 ,$$

per tant, si el mètode de Jacobi és convergent, també ho és el de Gauss-Seidel i el factor de convergència asimptòtica és el quadrat del de Jacobi.

Quin valor de  $\omega_0 \in (0, 2)$  minimitza el radi espectral  $\rho(B_\omega)$ ?

$\omega$  - òptim

$$\omega_0 = \frac{2}{1 + \sqrt{1 - \rho(B_J)^2}} \quad \text{i} \quad \rho(B_\omega) = \omega_0 - 1 .$$

# Exemple

Determineu les 10 primeres iteracions del mètode de Jacobi, del mètode Gauss-Seidel i del mètode de sobrerelaxació prenent  $x^{(0)} = (0, 0, 0, 0)^T$  del sistema  $Ax = b$  donat per

$$A = \begin{pmatrix} 10 & -1 & 2 & 0 \\ -1 & 11 & -1 & 3 \\ 2 & -1 & 10 & -1 \\ 0 & 3 & -1 & 8 \end{pmatrix} \quad b = \begin{pmatrix} 6 \\ 25 \\ -11 \\ 15 \end{pmatrix}$$

que té per solució  $x^* = (1, 2, -1, 1)^T$ .

Estudieu el residu per cada mètode.

# Exemple

$k$	0	1	2	3	4	5	6	7	8	9	10
$x_1^{(k)}$	0.0000	0.6000	1.0473	0.9326	1.0152	0.9890	1.0032	0.9981	1.0006	0.9997	1.0001
$x_2^{(k)}$	0.0000	2.2727	1.7159	2.053	1.9537	2.0114	1.9922	2.0023	1.9987	2.0004	1.9998
$x_3^{(k)}$	0.0000	-1.1000	-0.8052	-1.0493	-0.9681	-1.0103	-0.9945	-1.0020	-0.9990	-1.0004	-0.9998
$x_4^{(k)}$	0.0000	1.8750	0.8852	1.1309	0.9739	1.0214	0.9944	1.0036	0.9989	1.0006	0.9998

Figura: Iteracions Jacobi

$k$	0	1	2	3	4	5
$x_1^{(k)}$	0.0000	0.6000	1.030	1.0065	1.0009	1.0001
$x_2^{(k)}$	0.0000	2.3272	2.037	2.0036	2.0003	2.0000
$x_3^{(k)}$	0.0000	-0.9873	-1.014	-1.0025	-1.0003	-1.0000
$x_4^{(k)}$	0.0000	0.8789	0.9844	0.9983	0.9999	1.0000

Figura: Iteracions Gaus-Seidel

# Sistemes d'equacions lineals

## Precondicionadors

Documentació de MATLAB® - Iterative Methods for Linear Systems

# Preconditioning

Es pot millorar la convergència i l'estabilitat de la majoria de mètodes iteratius transformant el sistema lineal per tenir un espectre més favorable. Aquesta transformació es realitza aplicant una segona matriu, anomenada matriu preconditionadora, al sistema d'equacions. Aquest procés transforma el sistema lineal  $Ax = b$  en un sistema equivalent  $\tilde{A}\tilde{x} = \tilde{b}$

El preconditionador ideal ( $A^{-1}$ ) transforma la matriu de coeficients  $A$  en una matriu d'identitat. A la pràctica, trobar un bon preconditional requereix compensacions. La transformació ( $M$ ) potser de tres tipus:

- preconditionament per l'esquerre  $(M^{-1}A)x = (M^{-1}b)$  .
- preconditionament per la dreta  $(AM^{-1})(Mx) = b$  .
- split; usualment per matrius simètriques, la matriu preconditionadora  $M$  tal que  $M = HH^t$  (split) per mantenir la simetria del sistema transformat  $(H^{-1}AH^{-t})H^tx = (H^{-1}b)$  .

# Preconditioning

Direct solvers:  
Sequential, losing sparsity

Iterative solvers:  
easy parallel and sparse,  
but possibly slowly convergent

Combination of both methods:

Include preconditioner  $M \approx A$  in the form  $M^{-1} A x = M^{-1} b$ , such that

- $M$  is easy to deal with in parallel (reduced approximate direct solver)
- spectrum of  $M^{-1} A$  is much better clustered

Or include preconditioner  $M \approx A^{-1}$  in the form  $M A x = M b$ , such that

- $M$  is easy to deal with in parallel (reduced approximate inverse)
- spectrum of  $M A$  is much better clustered



# Sistemes d'equacions lineals

## Mètodes iteratius no estacionaris

Documentació de MATLAB® - Iterative Methods for Linear Systems

# Mètodes iteratius

Mètodes iteratius estacionaris, mètodes iteratius no estacionaris

Els mètodes no estacionaris difereixen dels mètodes estacionaris en què els càlculs impliquen informació que canvia en cada iteració. Normalment, les constants es calculen prenent productes interns de residus o altres vectors derivats del mètode iteratiu.

Alguns d'aquests mètodes són: Mètode del gradient conjugat (CG) i variants: MINRES, SYMMLQ, CGNE, CGNE, GMRES, BiCG, QMR, Bi-CGSTAB. Consulteu la bibliografia.

# Vector residu i vector gradient

$Ax = b$ ,  $A$  simètrica i definida positiva.

Resoldre el sistema lineal  $Ax = b$  és equivalent al problema de minimitzar la funció definida per

$$\phi(x) = \frac{1}{2}x^T Ax - x^T c \quad (7)$$

Obs. El gradient d'aquesta funció és  $\nabla\phi(x) = Ax - b$ .

# Sistemes lineals

## SOBREDETERMINATS

# Exemple

*Exemple.* Les dades de la Taula 5.2 s'han tret de J.C. Miller & J.N. Miller (1993), *Statistics in Analytical Chemistry*, Ellis Horwood. Corresponen a una investigació sobre un test colorimètric per a la concentració de glucosa, en la que es varen obtenir absorbàncies per a sis concentracions patró de glucosa.

En els experiments de calibratge de l'anàlisi instrumental es pren sempre com a variable de control  $x$  la concentració (de fet, al ser una concentració patró, el seu valor no és experimental, sinó prefixat per l'usuari). La variable resposta  $y$  és en aquest cas, l'absorbància. Ajustem per mínims quadrats un model  $y = a + bx$ .

TAULA 5.2

Concentració (mM)	0	2	4	6	8	10
Absorbància	0.002	0.150	0.294	0.434	0.570	0.704

# Sistemes lineals sobredeterminats

Sigui  $A$  una matriu  $m \times n$ ,  $m \geq n$ ,  $b$  un vector de  $m$  components,  $x$  el vector de  $n$  d'incògnites. El sistema d'equacions  $Ax = b$  no té solució, llavors busquem  $x$  tal que  $Ax$  sigui la millor aproximació de  $b$  (pel mètode dels mínims quadrats).

Vector residu:  $r_y = b - Ay$  per a  $y$  vector de  $n$  components.

## Teorema (Equacions normals)

*Si  $x$  és la solució dels sistema d'equacions normals,  $A^t(b - Ax) = 0$ , llavors*

$$\|r_x\|_2 \leq \|r_y\|_2 \quad \forall y \in \mathbb{R}^n.$$

## Teorema (Existència de solució)

*$A^t A$  és no singular si i només si  $\text{rank}(A) = n$*

# Equacions normals

$Ax = b$ ,  $m$  files i  $n$  incògnites amb  $\text{rang}(A)=n$ :

$$x_1 + x_2 = 1$$

$$x_1 + 2x_2 = 2$$

$$x_1 + 3x_2 = 5$$

✓  $A^tAX = A^tb$

✓  $RX = Q^tA^tb$

✓  $\|b - AX\|_2$

Equacions normals.

Solució per factorització  $QR$  de  $A^tA$ .

Residu mínim.

## ● Sistema lineal

$$\begin{array}{l}
 x_1 + x_2 = 1 \\
 x_1 + 2x_2 = 2 \\
 x_1 + 3x_2 = 5
 \end{array}
 \Rightarrow
 \begin{array}{l}
 \begin{cases} x_1 + x_2 = 1 \\ x_1 + 2x_2 = 2 \end{cases} \Rightarrow \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 1 \end{pmatrix} \quad \|r_x\| = 2 \\
 \begin{cases} x_1 + x_2 = 1 \\ x_1 + 3x_2 = 5 \end{cases} \Rightarrow \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} -1 \\ 2 \end{pmatrix} \quad \|r_x\| = 1 \\
 \begin{cases} x_1 + 2x_2 = 2 \\ x_1 + 3x_2 = 5 \end{cases} \Rightarrow \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} -4 \\ 3 \end{pmatrix} \quad \|r_x\| = 2
 \end{array}$$

$$A = \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{pmatrix} \Rightarrow A^t A = \begin{pmatrix} 3 & 6 \\ 6 & 14 \end{pmatrix} \Rightarrow x = \begin{pmatrix} -4/3 \\ 2 \end{pmatrix} \quad \|r_x\| = \frac{\sqrt{6}}{3} = 0.8165 < 1$$



# Guia estudi

## Llibre Càlcul numèric: teoria i pràctica

- Conceptes i exercicis resolts: capítol 4, pàgines 117-143.
- Problemes proposats: 1, 2, 3, 4, 5, 6, 7, 8, 9 i 13.
- Pràctiques resoltes : de la pàgina 147-154.
- Pràctiques proposades: pàgines 154-157.

## Llibre Cálculo Científico con MATLAB y Octave

- Conceptes i exercicis resolts: capítol 5, pàgines 127-170.
- Problemes i pràctiques proposades: del 5.1 al 5.17

# Llibres de consulta online



Llibre de consulta - Accès UPCommons,  
Càlcul numèric: teoria i pràctica



Llibre de consulta - Accès UPCommons,  
Cálculo numérico



Llibre de consulta - Accès Biblioteca,  
Cálculo Científico con MATLAB y Octave



Linear Equations,,  
Chapter 2



Llibre de consulta - Accès netlib.org,  
Barrett, R., M. Berry, T. F. Chan, et al.,  
*Templates for the Solution of Linear Systems: Building Blocks for  
Iterative Methods*, SIAM, Philadelphia, 1994.